Power Law: Base

https://gemini.google.com/app/b584e97c6adc6ec6

User prompt: Para mi clase de sistemas complejos estoy analizando una ley de potencia con el siguiente notebook, la intencion de todo esto es verificar como es que las etapas del sueño de los participantes pueden tener una tendencia a ser una ley de potencia, todo lo que se necesita saber ya esta dentro del notebook, ya sé ha realizado un grafico de los hipnogramas y todo lo que se pide pero justo antes de terminar el punto número dos de los objetivos se pide que se estime el valor p de los metodos, podrias ayudarme con ello ya que estan implementados estos

Response: 1. Estimación mediante OLS sobre log-log (Mínimos Cuadrados Ordinarios)

El enfoque tradicional, aunque estadísticamente deficiente para colas pesadas, consiste en linealizar la ley de potencia $p(x) \propto x^{-\alpha}$ mediante logaritmos: $\log(p(x)) = -\alpha \log(x) + c$. Al aplicar OLS sobre los puntos observados de tiempo-vida (frecuencia vs. duración), se obtiene una recta cuya pendiente es $-\alpha$.

Implementación en Python

Asumiendo que has extraído los `lifetimes` (tiempos-vida) y calculado sus frecuencias (probabilidades `p_x` para cada valor `x`):

```
import numpy as np
from scipy import stats

# Eliminar ceros para evitar errores en logaritmo
valid_idx = (x > 0) & (p_x > 0)
log_x = np.log10(x[valid_idx])
log_y = np.log10(p_x[valid_idx])

# Regresión OLS
slope, intercept, r_value, p_value, std_err = stats.linregress(log_x, log_y)

alpha_ols = -slope
r_squared = r_value**2

print(f"Alpha OLS: {alpha_ols:.4f}")
print(f"R^2: {r_squared:.4f}")
print(f"P-valor OLS: {p_value:.4e}")
```

Interpretación Rigurosa del P-valor y R^2 en OLS

- **P-valor (OLS):** En el contexto de `scipy.stats.linregress`, el p-valor prueba la hipótesis nula (H_0) de que **la pendiente de la recta es exactamente cero** (es decir, no hay correlación lineal en el espacio log-log). Un p-valor muy pequeño ($p < 0.05$) simplemente indica que la pendiente $-\alpha$ es estadísticamente diferente de cero. **Fallo crítico:** Esto *no* demuestra que los datos sigan una ley de potencia, solo demuestra que existe una tendencia decreciente en la gráfica log-log.
- **R^2:** Mide qué proporción de la varianza en $\log(p(x))$ es explicada por $\log(x)$. Valores altos (ej. $R^2 > 0.9$) son comúnmente malinterpretados como confirmación de una ley de potencia, pero otras distribuciones (como la log-normal o exponencial estirada) también pueden generar R^2 altos en OLS.

2. Método de Clauset (Máxima Verosimilitud con paquete `powerlaw`)

El formalismo de Clauset, Shalizi y Newman (2009) es el estándar actual en sistemas complejos. Utiliza Estimación de Máxima Verosimilitud (MLE) para calcular el exponente α y minimiza el estadístico de Kolmogorov-Smirnov (KS) para

encontrar el umbral óptimo $x_{\min}$ donde comienza el comportamiento de escala.

Implementación en Python

El paquete `powerlaw` procesa directamente los datos crudos (la lista completa de los tiempos-vida, no sus frecuencias pre-calculadas):

```
import powerlaw

# Ajuste directo a los datos crudos de tiempo-vida (L)
# L es una lista o array de enteros/flotantes que representan los tiempos-vida
fit = powerlaw.Fit(L, discrete=True) # discrete=True si los tiempos son múltiplos enteros de 30s

alpha_mle = fit.power_law.alpha
xmin = fit.power_law.xmin

print(f"Alpha MLE: {alpha_mle:.4f}")
print(f"xmin: {xmin}")

# 1. Comparación de distribuciones (Log-Likelihood Ratio)
R, p_ratio = fit.distribution_compare('power_law', 'lognormal', normalized_ratio=True)
print(f"Log-Likelihood Ratio (R): {R:.4f}")
print(f"P-valor (Ratio): {p_ratio:.4e}")
```

(Nota técnica: El verdadero p-valor de bondad de ajuste de Clauset requiere simulaciones de Monte Carlo explícitas que `powerlaw` no calcula por defecto con un simple atributo debido a su alto costo computacional. Sin embargo, en la práctica científica, el test de razón de log-verosimilitud (`distribution_compare`) es la métrica principal utilizada en este paquete para descartar alternativas).

Interpretación Rigurosa de las Métricas de Clauset

- **Prueba de Bondad de Ajuste (Monte Carlo / KS p-valor):** Si llegaras a implementar el remuestreo o usar una extensión para el p-valor estricto, la hipótesis nula (H_0) es que **los datos se generan a partir de una ley de potencia**.
    - Aquí la interpretación se invierte respecto a OLS: Si $p < 0.1$, se **rechaza** la ley de potencia (el ajuste es malo). Si $p \geq 0.1$, se asume que la ley de potencia es un modelo plausible.
- **P-valor del Log-Likelihood Ratio (`p_ratio`):** Este p-valor evalúa si la diferencia entre ajustar una ley de potencia frente a otra distribución (ej. log-normal o exponencial) es estadísticamente significativa.
    - H_0: Ambos modelos son igualmente buenos para describir los tiempos-vida.
    - Si $p < 0.05$ o $p < 0.1$: Un modelo es decididamente mejor que el otro. Se observa el signo de R. Si $R > 0$, la ley de potencia es mejor. Si $R < 0$, la distribución alternativa (ej. log-normal) explica mejor la dinámica de los hipnogramas.
    - Si $p > 0.1$: No hay evidencia suficiente para preferir una ley de potencia sobre una log-normal.

3. Comparación y justificación técnica de métodos

Para cumplir con el objetivo 3 de la práctica, la justificación de por qué el método de Clauset (MLE) es superior a OLS se basa en los siguientes argumentos teóricos:

1. **Manejo del ruido en la cola:** OLS asigna un peso desproporcionado a los eventos raros en la cola extrema (donde la frecuencia es muy baja y el ruido es alto). MLE ajusta la distribución probabilística considerando la densidad completa sin verse sesgado visualmente por los valores extremos dispersos.

2. **Suposición de varianza:** La regresión OLS asume que el error o ruido alrededor de la recta es de distribución normal e independiente de x. En el conteo de frecuencias de una ley de potencia empírica (como los segmentos de sueño), la varianza de los puntos en las colas no es gaussiana, sino de Poisson, violando los supuestos de Gauss-Markov que hacen válido al p-valor del OLS.
3. **Determinación de $x_{\min}$:** OLS requiere que el investigador mutile los datos a priori determinando visualmente desde dónde trazar la recta. El método de Clauset optimiza objetivamente el punto de inicio $x_{\min}$ calculando la distancia máxima entre las CDF empírica y teórica (mínimo estadístico KS).

User prompt: Okey pero como podria interpretar el valor P en ambos metodos de OLS y Clauset

Response: La interpretación del valor p cambia radicalmente entre ambos enfoques debido a que **la hipótesis nula (H_0) que evalúa cada método es fundamentalmente distinta**. En la estimación de leyes de potencia, una mala interpretación estadística del valor p es la causa principal de falsos positivos en la literatura científica.

A continuación, se desglosa el rigor estadístico de cada uno.

1. El valor p en Mínimos Cuadrados Ordinarios (OLS) sobre Log-Log

En una regresión lineal OLS ($\log y = \beta_1 \log x + \beta_0$), el valor p devuelto por los paquetes estadísticos estándar evalúa la significancia del coeficiente de la pendiente.

- **Hipótesis Nula (H_0):** La pendiente de la recta es exactamente cero ($\beta_1 = 0$). Es decir, no existe correlación lineal entre $\log(x)$ y $\log(y)$.
- **Interpretación:** Si $p < 0.05$, rechazas H_0 y concluyes que **existe una pendiente estadísticamente significativa**.
- **El fallo crítico (Por qué no sirve para leyes de potencia):** Un valor p minúsculo en OLS *no* demuestra que los datos sigan una ley de potencia. Cualquier distribución con una cola pesada o decreciente (como una exponencial, log-normal o Weibull) producirá una pendiente negativa en un gráfico log-log y, por ende, un valor $p \approx 0$.
- **Violación de supuestos:** OLS asume homocedasticidad (varianza constante del error) e independencia. En una distribución empírica log-log, las fluctuaciones en la cola (valores extremos con baja probabilidad) tienen una varianza mucho mayor (ruido de Poisson) que la cabeza de la distribución. Esto viola el Teorema de Gauss-Markov, invalidando matemáticamente la veracidad del valor p calculado por OLS.

2. El valor p de Bondad de Ajuste (Método Clauset / Monte Carlo)

El marco de Clauset, Shalizi y Newman no utiliza fórmulas asintóticas simples, sino un enfoque semi-paramétrico basado en el estadístico de Kolmogorov-Smirnov (KS) y simulaciones de Monte Carlo.

- **Hipótesis Nula (H_0):** Los datos empíricos **se generan a partir de una distribución de ley de potencia** (a partir del umbral $x_{\min}$).
- **Mecánica del cálculo:**
    1. Se calcula la distancia KS entre los datos empíricos y el modelo de ley de potencia ajustado.
    2. Se generan miles de conjuntos de datos sintéticos que *realmente* siguen esa ley de potencia exacta.
    3. Se ajusta cada conjunto sintético y se calcula su propia distancia KS.
    4. El valor p es la fracción de conjuntos sintéticos cuya distancia KS es mayor que la distancia KS empírica.

- **Interpretación (Lógica invertida):** Aquí *quieres* que H_0 sobreviva.
    - **Si $p \leq 0.1$:** Rechazas H_0. La distancia entre tus datos y el modelo es demasiado grande para atribuirse al azar. **Los datos NO siguen una ley de potencia.** (Nota: Clauset eleva el nivel de significancia empírico a 0.1 en lugar del 0.05 tradicional para ser más conservador contra los falsos positivos).
    - **Si $p > 0.1$:** No puedes rechazar H_0. Concluyes que la ley de potencia es un modelo **plausible** para tus datos.

3. El valor p de la Razón de Verosimilitud (Model Selection)

Incluso si el valor p de bondad de ajuste sugiere que una ley de potencia es plausible ($p > 0.1$), otra distribución podría explicar los datos aún mejor. Aquí entra el *Log-Likelihood Ratio test* (Test de Vuong), que en el paquete `powerlaw` arroja el valor `p_ratio`.

- **Hipótesis Nula (H_0):** Ambos modelos (ej. ley de potencia vs. log-normal) están a la misma distancia de la verdadera distribución subyacente. Ninguno es estadísticamente superior al otro.
- **Interpretación conjunta con el Ratio (R):**
    - **Si `p_ratio` < 0.1:** Rechazas H_0. Un modelo es definitivamente mejor. Debes mirar el signo del Log-Likelihood Ratio (R).
        - Si $R > 0$: La ley de potencia es el mejor modelo empírico.
        - Si $R < 0$: La distribución alternativa (ej. log-normal) es el mejor modelo empírico.
    - **Si `p_ratio` ≥ 0.1:** La varianza en los datos es muy alta o la diferencia entre las verosimilitudes de ambos modelos es muy pequeña. Estadísticamente, no hay información suficiente en la muestra empírica para afirmar que un modelo domina al otro. Ambos son igualmente viables.

User prompt: Okey en todo esto quisiera saber unas cosas muy puntuales que me ayudaran a comprender más lo que estoy realizando y a interpretar mejor cada uno de los parametros. Lo que quisiera saber es lo siguiente: 1. Se esta realizando un estimador OLS para estimar una ley de potencia, entonces estamos dando por hecho que las frecuencias del lifetime del sueño sigue una ley de potencia?? 2. Aqui en este caso puntalmente a que se refiere con p-value y R^2

Response: Introducción

Para comprender rigurosamente lo que ocurre al aplicar un estimador de Mínimos Cuadrados Ordinarios (OLS) sobre distribuciones empíricas, es fundamental separar la **fenomenología** (ajustar una curva a puntos de datos) de la **mecánica generativa** (el proceso físico o biológico que crea los datos). Cuando transformamos una función no lineal mediante logaritmos para usar herramientas de estadística lineal, alteramos no solo la geometría del problema, sino también la estructura del error subyacente, lo cual cambia radicalmente la interpretación de las métricas de ajuste.

Ejemplo del mundo real

Imagina el registro continuo del sueño de un paciente a través de un electroencefalograma (EEG), segmentado en épocas estándar de 30 segundos. Si observamos la fase de sueño profundo, contamos cuántas veces el paciente permanece en esa fase durante 1 época (30s), 2 épocas (60s), 10 épocas (300s), etc.

Al graficar la duración de la fase (tiempo-vida) contra su frecuencia de aparición en escalas logarítmicas, visualmente podríamos notar una caída diagonal. Si trazamos una línea recta con OLS sobre esos puntos, estamos obligando a la geometría lineal a describir el fenómeno. ¿Significa esto que la dinámica neuronal que rige las transiciones del sueño obedece estrictamente a una ley de potencia? No necesariamente. Podría ser un proceso de decaimiento exponencial con múltiples escalas de tiempo que, en un rango limitado, *parece* una línea recta.

Desarrollo técnico

Para responder a tus dudas puntuales sobre los parámetros que estás obteniendo en tu análisis:

1. Sobre el supuesto al usar OLS para estimar una Ley de Potencia

Respuesta corta: Sí, al usar OLS estás asumiendo *a priori* que la relación es una ley de potencia, pero el estimador en sí mismo **no prueba ni verifica** que esa suposición sea correcta.

Análisis profundo: Cuando tienes una relación teórica de la forma $P(x) \propto x^{-\alpha}$ y aplicas logaritmos en ambos lados, obtienes la ecuación de una recta:

$$\log P(x) = -\alpha \log x + C$$

Al alimentar un algoritmo OLS con tus arrays de $\log(x)$ (duraciones de la fase de sueño) y $\log(P(x))$ (frecuencias), el algoritmo está diseñado para resolver un único problema de optimización: minimizar la suma de los errores cuadráticos entre los puntos empíricos y una línea recta.

El OLS **da por hecho** que el modelo subyacente es lineal en ese espacio logarítmico. Si tus datos de las épocas de sueño en realidad siguieran una distribución Lognormal o una Exponencial Estirada, el OLS haría exactamente lo mismo: trazaría la "mejor" línea recta posible a través de una curva, y te devolvería una pendiente (tu exponente α). Por lo tanto, OLS es un estimador de parámetros condicionando a que el modelo sea correcto; no es una prueba empírica de que los tiempos-vida del sueño sean fractales o invariantes de escala.

2. Interpretación puntual del valor p y R^2 en el contexto del sueño con OLS

En el marco estricto de tu regresión OLS sobre los tiempos-vida, las métricas estándar de los paquetes estadísticos (como `scipy.stats.linregress` o `statsmodels`) significan lo siguiente:

A. El coeficiente de determinación (R^2)

- **Significado técnico:** Mide la proporción de la varianza en la variable dependiente ($\log P(x)$) que es explicable y predecible a partir de la variable independiente ($\log x$).
- **Interpretación en tu caso:** Si obtienes un $R^2 = 0.92$, significa que el 92% de la variación en el logaritmo de las frecuencias de tus tiempos-vida se alinea con el logaritmo de las duraciones.
- **La trampa analítica:** Un R^2 alto en un gráfico log-log **no valida** una ley de potencia. ¿Por qué? Porque el logaritmo comprime masivamente los ejes. Una curva parabólica suave en espacio log-log (característica de una Lognormal) puede ajustarse con una recta obteniendo R^2 superiores a 0.90, simplemente porque la compresión de los datos enmascara la curvatura real.

B. El valor p (p-value de la regresión OLS)

- **Hipótesis nula (H_0):** En el contexto de OLS, la hipótesis nula es estrictamente que **la pendiente de la recta verdadera es igual a cero** ($\beta_1 = -\alpha = 0$). En tu escenario, esto significaría que la frecuencia de un estado de sueño no tiene ninguna relación lineal (en espacio log-log) con el tiempo que dura ese estado.
- **Interpretación en tu caso:** Si obtienes un valor p muy pequeño (ej. $p < 0.001$), simplemente estás rechazando H_0. Estás concluyendo: *"Tengo evidencia estadística suficiente para afirmar que la pendiente no es plana; a medida que las duraciones (épocas) del sueño aumentan, su frecuencia de aparición cambia sistemáticamente"*.
- **El rigor estadístico:** Fíjate que el valor p del OLS **no evalúa la bondad de ajuste**. No te dice "esta distribución es una ley de potencia". Solo te dice "esta nube de puntos en el gráfico log-log tiene una inclinación que no es cero". Además, como el ruido en las colas de tus datos empíricos (tiempos-vida muy largos y raros) viola el supuesto de homocedasticidad (varianza constante del error), el cálculo del valor p en OLS está matemáticamente sesgado y tiende a ser artificialmente cercano a cero.

Recomendaciones

1. **Abandona el valor p de OLS como métrica de validación:** Para afirmar rigurosamente que las transiciones de sueño de tus pacientes siguen dinámicas de invariancia de escala, el OLS solo debe usarse como una exploración visual preliminar, no como demostración concluyente.
2. **Transición al contraste de hipótesis (Clauset):** Si deseas saber si la distribución es genuinamente una ley de potencia, debes dejar de preguntar "qué inclinación tiene la recta" y empezar a preguntar "¿cuál es la distancia máxima (Kolmogorov-Smirnov) entre mis datos de sueño crudos y una ley de potencia teórica pura?".
3. **Contraste de modelos (Log-Likelihood Ratio):** Si tus datos muestran un umbral de ruido o curvatura, te sugiero calcular el test de Vuong (razón de verosimilitudes) para enfrentar matemáticamente tu ley de potencia estimada contra una distribución Exponencial y una Lognormal. ¿Podría ser que la fisiología imponga un "corte" exponencial (corte de escala) a la duración máxima que el cerebro puede mantener un estado sin despertar? Investigar eso aportará mucha mayor solidez a tu análisis.

---

*User prompt: Ahora quisiera que me dijeras, sencillamente, cual es la diferencia que hay entre el alpha_ols y el p-valor de la pendiente más explicitamente del siguiente codigo que tengo: # Estimación OLS para cada sujeto resultados_ols = [] for sujeto, serie in hipnogramas.items(): lfts = calcular_lifetimes(serie) # Obtener pares únicos (Lifetime L, Frecuencia N(L)) valores, conteos = np.unique(lfts, return_counts=True) # Transformación a escala logarítmica (base 10) log_l = np.log10(valores) log_n = np.log10(conteos) # Regresión lineal ordinaria: log10(N) = intercepto + slope * log10(L) res = stats.linregress(log_l, log_n) # Parámetros extraídos alpha_ols = -res.slope # Exponente alpha = -pendiente r_squared = res.rvalue ** 2 # Coeficiente de determinación R^2 p_value = res.pvalue # p-valor de la pendiente std_err = res.stderr # Error estándar de la pendiente intercept = res.intercept # Intercepto beta_0 resultados_ols.append({ 'Sujeto': sujeto, 'alpha_ols': alpha_ols, 'r2': r_squared, 'p_value': p_value, 'std_err': std_err, 'intercept': intercept, 'n_puntos': len(valores) # Número de puntos distintos graficados }) # DataFrame ordenado con todos los resultados df_resultados_ols = pd.DataFrame(resultados_ols) # Mostrar la tabla completa o guardar a CSV print(df_resultados_ols.to_string(index=False))*

Response: El `alpha_ols` mide la **magnitud** de la caída en tu gráfica de frecuencias, mientras que el `p-value` evalúa la **confiabilidad estadística** de que esa caída (y no una línea plana) realmente exista en tus datos.

Introducción

En tu análisis de hipnogramas, la función `stats.linregress` toma las coordenadas de los tiempos-vida (`log_l`) y sus frecuencias (`log_n`) para trazar la línea recta que mejor se ajuste a esos puntos. El código extrae dos propiedades distintas de esa misma línea: su grado de inclinación (`alpha_ols`) y la probabilidad matemática de que dicha inclinación sea producto del azar (`p_value`).

Ejemplo del mundo real

Imagina que estás midiendo la inclinación de la ladera de una montaña tomando puntos con un GPS. El `alpha_ols` es la inclinación calculada: te dice qué tan empinada es la bajada (por ejemplo, desciende 2 metros por cada metro avanzado). El `p_value` responde a otra pregunta: ¿Qué tan seguro estás de que realmente estás en una bajada y no en un terreno plano que resultó tener algunos baches aleatorios que engañaron a tu GPS? Si el `p_value` es minúsculo, la bajada es indiscutible.

Desarrollo técnico

Para interpretar tu `df_resultados_ols` de forma rigurosa, la distinción matemática de las variables de tu código es la siguiente:

1. `alpha_ols = -res.slope` (El Exponente de Decaimiento)

- **Qué es:** Es el valor absoluto de la pendiente de la regresión lineal.
- **Qué significa en tu investigación:** Cuantifica la dinámica del sueño del sujeto. Un `alpha_ols` alto (ej. 2.5) indica que la probabilidad de que una fase de sueño dure mucho tiempo colapsa drásticamente; los tiempos-vida

son predominantemente cortos. Un `alpha_ols` bajo (ej. 1.5) sugiere colas más pesadas, donde el sujeto logra mantener estados de sueño prolongados con mayor frecuencia.

2. `p_value = res.pvalue` (La Prueba de Pendiente Cero)

- **Qué es:** Es la probabilidad de obtener esa pendiente (`res.slope`) si en realidad la pendiente verdadera fuera exactamente cero (hipótesis nula, H_0).
- **Qué significa en tu investigación:** Te protege contra fluctuaciones aleatorias. Si para un sujeto obtienes un `p_value` de 0.85, significa que los puntos `(log_l, log_n)` están tan dispersos que la recta trazada no es estadísticamente diferente de una línea horizontal. En ese caso, el `alpha_ols` calculado pierde validez.
- **La advertencia fundamental:** Este `p_value` de `scipy.stats` **no** valida que las frecuencias sigan una ley de potencia. Solamente valida que la relación entre `log_l` y `log_n` no es plana, es decir, que la frecuencia disminuye conforme el lifetime aumenta.

Para guiar tu comprensión sobre la interacción de ambos: *¿Qué pasaría con el `p_value` si un paciente tiene un sueño muy fragmentado y tu código solo extrae muy pocos puntos únicos de lifetime (un `n_puntos` pequeño)? ¿Serías igual de confiable al afirmar que su `alpha_ols` representa un decaimiento sistemático en lugar de puro ruido?*

Recomendaciones

Al momento de analizar tu tabla final `df_resultados_ols` a lo largo de todos los pacientes:

- Utiliza el `p_value` como un filtro de exclusión. Si un sujeto presenta un `p_value > 0.05`, ignora su `alpha_ols` porque la regresión sobre sus hipnogramas carece de significancia estadística.
- Concéntrate en el `alpha_ols` para comparar fenotipos. Una vez que te aseguras de que el `p_value` es cercano a cero en los sujetos, utiliza el `alpha_ols` para contrastar cómo cambian las distribuciones de los estados de sueño entre los distintos perfiles de los pacientes.
